

Rezumat Curs 1 — Introducere în Machine Learning & Sisteme Inteligente

Surse: 01_ML_intro.pdf + 1__Sisteme_inteligente.md UBB Informatică Anul 2 — Inteligență Artificială

1. Ce este Machine Learning (ML)?

Machine Learning este o ramură a Inteligenței Artificiale care se ocupă cu crearea de sisteme capabile să **învețe singure din date**, fără a fi programate explicit pentru fiecare sarcină.

Definiții relevante

- **Arthur Samuel (1959):** "field of study that gives computers the ability to learn without being explicitly programmed"
- **Tom Mitchell (1998):** un program învață din experiența **E** față de sarcina **T** cu măsura de performanță **P**, dacă performanța sa pe **T** (măsurată prin **P**) se îmbunătățește cu experiența **E**.
- **Yoshua Bengio et al. (2016):** "studiul algoritmilor care se îmbunătățesc prin experiență și extrag tipare din date pentru a face predicții sau decizii"

Programare tradițională vs. Machine Learning

Aspect	Programare tradițională	Machine Learning
Input	Date + Reguli → Calculator	Date + Răspunsuri corecte → Calculator
Output	Răspunsuri	Reguli (model)
Adaptare	Manuală	Automată
Exemple	Calculatoare de buzunar	Filtre spam, recunoaștere imagini

Esența ML: În programarea clasică, programatorul scrie regulile. În ML, **calculatorul descoperă singur regulile** din exemple.

2. Proiectarea unui Sistem de Învățare Automată

Orice sistem ML este proiectat urmând un framework cu trei întrebări fundamentale:

1. **Ce modele de predicție sunt posibile?** → Ipotezele care se validează
2. **Cât de bun este un model?** → Funcția de cost (loss function)
3. **Cum se identifică cel mai bun predictor?** → Algoritmul de optimizare

Pașii proiectării

1. **Stabilirea scopului** — Ce vrem să învețe sistemul? (clasificare, regresie, clustering etc.)
 2. **Alegerea algoritmului de învățare** — Algoritmul induce ipoteze care:
 - se potrivesc cu datele de antrenament
 - generalizează cât mai bine pe date nevăzute (date de test)
 3. **Definirea funcției de cost** — Minimizarea erorii:
 - Eroarea de predicție (distanța valorilor prezise față de valorile reale)
 - Eroarea de clasificare (câte exemple au fost clasificate greșit)
 4. **Evaluarea sistemului** — Experimental (cross-validare, acuratețe) sau teoretic (complexitate computațională)
-

3. Tipologia Sistemelor de Învățare Automată

A. După experiența din timpul învățării

3.1 Învățare Supervizată

- **Definiție:** Datele de antrenament sunt **etichetate** (se cunosc perechile intrare–ieșire)
- **Scop:** Să se determine o funcție $f: \text{atribute} \rightarrow \text{ieșire}$ care generalizează pe date noi
- **Feedback:** Direct — algoritmul se adaptează la perechile cunoscute
- **Notatii formale:**
 - Date de antrenament: $\{(\text{atribute}_i, \text{ieșire}_i)\}_{i=1}^N$
 - Date de test: $\{(\text{atribute}_i)\}_{i=1}^n$
- **Tipuri de probleme:**
 - **Clasificare** — ieșirea este o categorie dintr-o mulțime finită (ex: spam/non-spam, diagnostic medical)
 - **Regresie** — ieșirea este un număr real (ex: prețul unui imobil)
- **Exemple:** regresie liniară, SVM, rețele neuronale, arbori de decizie

3.2 Învățare Nesupervizată

- **Definiție:** Datele de antrenament **NU sunt etichetate** — nu se cunosc ieșirile
- **Scop:** Descoperirea de structuri/tipare ascunse în date
- **Feedback:** Inexistent (nu există ieșiri de referință)
- **Exemple de probleme:**
 - **Clustering (clusterizare)** — gruparea datelor similare (ex: zone cu cazuri COVID concentrate)

- **Reducerea dimensionalității** — comprimarea datelor păstrând informația esențială
- **Algoritmi:** k-Means, PCA

3.3 Învățare cu Întărire (Reinforcement Learning)

- **Definiție:** Un agent interacționează cu un mediu și primește **recompense/penalizări** pentru acțiuni
- **Scop:** Învățarea unui model optim de acțiune (politică)
- **Caracteristici:**
 - Predicție de secvențe de decizii/acțiuni
 - Sistem de recompense pentru fiecare decizie
 - Datele sunt **secvențiale și corelate** (nu i.i.d. ca în supervizat)
- **Exemple:** AlphaGo, jocuri video, roboți autonomi, planificare

3.4 Tabelul comparativ complet

Aspect	Supervizat	Nesupervizat	Cu întărire
Date	Etichetate	Neetichetate	Secvențiale
Feedback	Instructiv	Absent	Evaluativ (recompensă)
Scop	Predicție	Descoperire structuri	Acțiune optimă
Exemplu	Clasificare email	Clustering clienți	AlphaGo

B. După modelul învățat (algoritmul)

- Rețele neuronale artificiale
- Mașini cu suport vectorial (MSV/SVM)
- Algoritmi evolutivi
- k-Nearest Neighbors (kNN)
- Arbori de decizie
- Modele Markov ascunse

4. Tipuri de Scopuri / Probleme în ML

4.1 Clasificare

Maparea unei intrări la una dintre k **clase discrete predefinite**.

Formal: Se dau $(x_i, y_i)_{i=1}^N$ unde $y_i \in \{C_1, C_2, \dots, C_k\}$. Se învață $f(x) \rightarrow C_j$.

Exemplu: Detectarea tumorilor (vasculară / nevasculară / angiogenă), detectarea COVID din RMN.

4.2 Regresie

Maparea unei intrări la un **număr real continuu**.

Formal: Se dă $(x_i, y_i)_{i=1}^N$ unde $y_i \in \mathbb{R}$. Se învață $f(x) \approx y$.

Exemplu: Predicția prețului unui imobil pe baza numărului de camere, vechimii, suprafeței.

4.3 Clusterizare (Clustering)

Gruparea datelor **fără etichete** în clustere omogene.

Exemplu: Identificarea zonelor geografice cu concentrare mare de cazuri COVID.

4.4 Planificare

Generarea unei **secvențe de acțiuni** optime pentru atingerea unui scop.

Exemplu: Un robot care găsește drumul optim de la punctul A la punctul B.

4.5 Regresie simbolică

Descoperirea **formeii funcției matematice** care descrie datele.

Exemplu: Găsirea formulei curbei care aproximează un contur geografic.

5. Calitatea Învățării & Evaluarea Modelelor

5.1 Metrice de performanță

Acuratețea (Accuracy):

$$Acc = \frac{\text{nr. exemple corect clasificate}}{\text{nr. total de exemple}}$$

Calculată atât în **faza de antrenare**, cât și în **faza de testare**.

5.2 Metode de evaluare

Seturi disjuncte antrenare/test

- Se împarte dataset-ul în: **set de antrenare** (+ opțional set de validare) + **set de testare**
- Parametrii modelului se estimează pe setul de antrenare; cei mai buni parametri (obținuți pe validare) se folosesc pentru modelul final
- **Recomandat pentru:** seturi de date mari

Validare încrucișată (k-fold Cross-Validation)

- Datele de antrenament se împart în **h subseturi egale**
- La fiecare iterație: (h-1) subseturi → antrenare, 1 subset → validare
- Performanța finală = media pe cele h rulări
- **Recomandat pentru:** seturi de date mici (tipic h = 5 sau h = 10)

$$CV_{(h)} = \frac{1}{h} \sum_{i=1}^h \text{Error}_i$$

Leave-One-Out Cross-Validation (LOOCV)

- Caz particular: h = numărul total de exemple
- La fiecare iterație, un singur exemplu este lăsat pentru validare
- **Recomandat pentru:** seturi de date foarte mici

5.3 Dificultăți în Învățare

Overfitting (Învățare pe derost / Supra-potrivire)

- **Definiție:** Modelul se potrivește prea accentuat cu datele de antrenament, dar **nu generalizează** pe date noi
- **Simptom:** Performanță bună pe antrenament, **performanță slabă pe test**
- **Cauze:** Model prea complex, prea puține date
- **Soluții:** Regularizare, reducerea complexității modelului, mai multe date, cross-validare

Underfitting (Sub-potrivire)

- **Definiție:** Modelul este prea simplu și **nu captează tiparele** din date
- **Simptom:** Performanță slabă **atât pe antrenament cât și pe test**
- **Soluții:** Model mai complex, mai multe feature-uri, mai multe iterații de antrenare

6. Principiul de Bază al Algoritmilor ML

Orice algoritm de ML are ca principiu fundamental:

$\text{Minimizarea unei funcții de cost (loss function) pe datele de antrenament}$

Tipuri de erori minimizate:

- **Eroarea de predicție** — distanța dintre valorile prezise și valorile reale
- **Eroarea de clasificare** — numărul de exemple clasificate greșit
- **Eroarea structurală** — cât de neomogene sunt structurile produse (în clusterizare)

7. ⚠ Aspecte Critice pentru Examen

Tipare identificate în SUBIECT_EXAMEN_2025

Întrebare tip 1 — Citirea unui grafic de regresie:

"Se dă un model liniar. Precizați prețul previzionat pentru X ." → Necesită înțelegerea conceptului de regresie (Curs 1) + citire de grafic

Întrebare tip 2 — Compararea a două modele:

"Două modele diferite, care are eroarea medie pătratică mai mare?" → Înțelegerea funcției de cost și a conceptului de eroare (Curs 1 + Curs 2)

Întrebare tip 5 — Concepte LLM:

"GPT-3 este un LLM? ChatGPT este un LLM?" → Necesită fundamente clare de tipologie ML din Curs 1

Concepte cheie de memorat

1. Diferența supervizat / nesupervizat / cu întărire
2. Clasificare vs. regresie (tip de ieșire!)
3. Overfitting vs. underfitting (simptome și soluții)
4. Cross-validare — când se folosește și cum funcționează
5. Funcția de cost = măsura calității modelului
6. Framework proiectare ML: ipoteze → funcție cost → algoritm de optimizare

Rezumat generat exclusiv din 01_ML_intro.pdf și 1__Sisteme_inteligente.md