

Subiectul I – pag 1

1. (600p) Completați afirmațiile de mai jos:

- În învățarea supervizată, setul de date este format din perechi de _____, utilizate pentru a învăța o funcție de predicție.
- În cazul regresiei logistice, clasificarea se bazează pe utilizarea funcției _____ pentru a produce o ieșire între 0 și 1.
- operatorul de încrucișare lucrează la nivel de _____, iar cel de selecție la nivel de _____.
- În cazul problemei plății sumei S folosind 4 monezi de valori diferite, arborele asociat spațiului de căutare explorat de către un algoritm de căutare exhaustivă va avea un număr de frunze egal cu: _____.
- Dacă o dată (numerică) din setul nostru de date, deviază foarte mult de la distribuția celorlalte, se numește _____.
- Pentru a crea indivizi noi într-un algoritm genetic, se aplică următorii pași: se aleg părinții prin utilizarea unui algoritm de _____, Părinții sunt combinați prin pasul de _____, iar cromozomului rezultat i se adaugă informație nouă în pasul de _____.
- Gradient descent urmărește minimizarea _____ în vederea găsirii valorilor optime ale coeficienților modelului.
- Notăm dimensiunea latentă (embedding-ul) unui cuvânt ca $Emb(cuv)$. Atunci $Emb("Franța") - Emb("România") + Emb("București")$ este aproximativ egal cu $Emb(_____)$.
- operatorul de mutație din algoritmi evolutivi are aritate egală cu _____.
- În cazul unei probleme de clasificare a tweet-urilor în pozitive și negative pe baza prezenței sau absenței a 3 hash tag-uri (#happy, #fun, #sad), un arbore de decizie poate avea maxim _____ nivele (nodul rădăcină se află pe nivelul 1).
- În algoritmi evolutivi, scopul operatorului de selecție este de a favoriza supraviețuirea soluțiilor cele mai bune, pe când scopul operatorului de mutație este _____.
- TF.IDF este un concept care poate fi folosit când se procesează informații de tip _____.

2. (50p) Pentru o rețea neuronală artificială, care din înșiruirile următoare descriu un subset de hyperparametri ai rețelei?

- datele de intrare, ponderile (weight-urile) neuronilor, numărul de epoci
- datele de ieșire, bias-urile (termenii liberi ai) neuronilor, ponderile (weight-urile) neuronilor
- funcția de cost (loss), funcția/funcțiile de activare, numărul de straturi neuronale
- rata de învățare, funcția/funcțiile de activare, numărul de straturi neuronale

3. (100p) O rețea neuronală convoluțională formată dintr-un singur strat având un singur neuron primește ca input o matrice de 6x6. Dacă neuronul rețelei are 4 ponderi (weight-uri) dispuse în forma de 2x2 și un bias, iar el efectuează operațiunea de convoluție cu pasul (stride-ul) 1 care va fi dimensiunea hărții de activare/feature-uri (activation/feature map-ului) rezultante? Justificați răspunsul.

4. (100p) Se consideră k melodii, fiecare melodie având o anumită durată. Să se împartă melodiile în exact n playlists disjuncte nenule astfel încât duratele acestor n playlists să fie identice (k, n – numere naturale, $n < k$). Precizați care afirmații sunt adevărate.

- Un algoritm genetic pentru rezolvarea acestei probleme folosește cromozomi a căror reprezentare este un vector cu n elemente cu toate valorile din $\{1, 2, \dots, k\}$
- Un algoritm genetic pentru rezolvarea acestei probleme folosește cromozomi a căror reprezentare este un vector cu n elemente binare
- Un algoritm genetic pentru rezolvarea acestei probleme folosește cromozomi a căror reprezentare este un vector cu k elemente cu toate valorile din $\{1, 2, \dots, n\}$
- Un algoritm genetic pentru rezolvarea acestei probleme folosește cromozomi a căror reprezentare este un vector cu k elemente cu toate valorile din $\{1, 2, \dots, k\}$

5. (200p) Prezentați o asemănare între

- Algoritmi genetici și algoritmi de tip ACO (Ant Colony Optimisation)

- cele 2 mecanisme de rezolvare a unei probleme de regresie: Stochastic Gradient Descent și Batch Gradient Descent

Subiectul 1 – pag. 4

6. (50p) Considerand biblioteca numpy (import numpy as np) si functia np.dot disponibila in aceasta biblioteca pentru realizarea dot product-ului (produsului scalar), pentru urmatorul cod Python: $y = \text{np.dot}([1,2,3], [3,2,1])$ care dintre urmatoarele afirmatii este adevarata?

- a. Codul va produce o eroare fiindca al doilea parametru al produsului scalar trebuie sa fie un scalar (ex. $\text{np.dot}([1,2,3], 4)$, iar atunci valoarea lui y devine $[4,8,12]$)
- b. $y = 10$
- c. Codul va produce o eroare fiindca produsul scalar nu se poate efectua pentru vectori/array-uri unidimensionale
- d. $y = [3, 4, 3]$

7. (50p) Într-un Large Language Model (LLM), parametrul temperatură din funcția de inferență are următorul efect:

- a. Temperatura afectează sentimentul răspunsului (temperatura mai mare „caldă” generează un răspuns informal, iar cea mică „rece” un răspuns formal)
- b. Temperatura determină „creativitatea” răspunsului (temperatura mică duce la folosirea celor mai probabile cuvinte, iar temperatura mare permite utilizarea cuvintelor mai puțin probabile în răspuns).
- c. Temperatura este parametrul responsabil pentru lungimea răspunsului.
- d. Temperatura nu este un parametru folosit la inferență, ci la pasul de fine-tuning, pentru a modifica influența pe care datele noi o au asupra modelului preantrenat.

8. (100p) Un arbore de decizie a împărțit, pe baza unei singure condiții, datele de antrenament (în număr de 100) prezentate sub forma unor emailuri (bune sau spam-uri) în 2 submulțimi S1 și S2 astfel: S1 conține 30 emailuri bune și 30 spam-uri, iar S2 conține 40 de spam-uri. Calculați entropia mulțimilor S1 și S2 (justificați calculele efectuate).

9. (100p) Un algoritm de etichetare automată a 20 de cuvinte (primele 10 fiind substantive, urmatoarele 6 verbe si ultimele 4 adjective) a stabilit că primele 4 cuvinte si ultimele 2 cuvinte sunt substantive, cele 2 cuvinte din mijloc sunt verbe, iar restul sunt adjective). Care este performanța algoritmului?

- a. algoritmul are o acuratețe de 40%
- b. algoritmul are o precizie medie de aprox. 66.6%
- c. rapelul clasificării substantivelor este de 40%
- d. algoritmul are o acuratețe de 35%

10. (200p) Fie o problemă de recunoaștere a uneia din literele A, B sau C în imagini. Pentru început, se folosește un set de date de antrenament format din 10 imagini gri de 4x4 pixeli. Se dorește rezolvarea problemei cu ajutorul unei rețele neuronale cu 2 straturi ascunse, fiecare cu câte 2 neuroni. Toți neuronii din rețea au asociate ca funcții de activare funcția sigmoid.


- a. Precizați și justificați numărul de neuroni de pe stratul de intrare

- b. Precizați și justificați numărul de coeficienți/ponderi ai/ale rețelei care trebuie optimizate. Justificați răspunsul.

11. (100p) Definiți și exemplificați un concept învățat în cadrul cursului de IA. Folosiți maxim 100 de cuvinte.


12. O agenție imobiliară dorește să estimeze prețul unor locuințe. Pentru aceasta, agenția ia în calcul diferite informații precum: vechimea clădirii, numărul de băi, numărul de camere.

- a. (50p) În cazul folosirii unei singure informații pentru previziunea prețului unui imobil (de exemplu, numărul de camere) s-a obținut un model liniar de forma celui prezentat în figura de mai jos. Precizați care este prețul previzionat pentru un imobil cu 3 camere.




Subiectul I – pag 3


- b. (100p) În cazul unor experimente, folosind două seturi de date de antrenare diferite, au fost identificate două modele de predicție (prezentate în figura alăturată). Precizați care dintre acestea are eroarea medie pătratică mai mare. Justificați răspunsul.





Model 1




Model 2



- c. (100p) După o analiză mai atentă s-a observat că relația dintre prețul imobilului și vechimea acestuia nu este liniară. După anumite transformări aplicate datelor, se poate observa totuși un model liniar de dependență precum cel din figura alăturată. Explicați cum ar putea fi construit un astfel de model liniar de predicție a prețului unui imobil pe baza vechimii imobilului.



13. (100p) O echipă de specialiști a construit un model de predicție util în identificarea posibilității ca un meteorit să ciocnească Terra (folosind o bază de antrenare format din meteoriții care în ultimii 50 de ani au ciocnit Terra sau au trecut pe lângă ea). Modelul construit a înregistrat, pe setul de antrenare, o acuratețe de 99%. Este acest model de predicție performant? Justificați răspunsul.



14. (50p) Spitalul Cluj a descoperit o nouă boală mortală. Din fericire aceasta este tratibilă dacă este depistată din timp. Ai fost angajat să antrenezi și evaluezi un model care pe baza datelor medicale diagnostichează pacientul. Ai obținut 4 modele, cu performanțele descrise mai jos. Pe care dintre acestea îl vei folosi?

- a. Modelul 1 cu F1-score 0.85
b. Modelul 2 cu Acuratețe 0.9

- c. Modelul 3 cu Recall 0.7 și Precision 0.9
d. Modelul 4 cu Recall 0.9 și Precision 0.7

15. (50p) Care dintre următoarele afirmații nu sunt adevărate pentru embedding-urile obținute prin metoda one-hot encoding?

- a. Vectorii rezultanti contin valori de 0 și 1.
b. Vectorii rezultanti surprind relația semantică dintre cuvinte.

- c. Reprezentare ineficientă a cuvintelor în cazul vocabularelor extrem de lungi.
d. Vectorii rezultanti contin doar valori numerice.

16. (50p) Care din următoarele afirmații sunt corecte și complete?

- a. ChatGPT este un LLM
b. GPT-3 este un LLM

- c. GPT-3 este un sistem care conține un LLM
d. ChatGPT este un sistem care conține un LLM

17. (50p) Care dintre următoarele concepte pot reprezenta derivări prin relația de moștenire ale conceptului de Metodă de învățare supervizată:

- a. Încrucișare

- b. Rețea Neuronală

- c. Algoritm Evolutiv

- d. Greedy

18. (50p) Precizați câți coeficienți trebuie optimizați în cazul folosirii unei rețele neuronale artificiale cu un strat ascuns cu 2 neuroni pentru predicția consumului de combustibil a unor vehicule pe baza puterii motorului și a anului de fabricație a vehiculului. Exclueți din calcule bias-ul.

- a. 4

- b. 6

- c. 2

- d. 8